

pragma | YouTube

RETO TÉCNICO

JESUS ANTONIO VILLARRAGA PALOMINO

Contenido

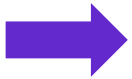
1. Contextualización y Objetivo
2. Métodología CRISP-DM
3. Resultados
4. Modelamiento
5. Conclusiones y recomendaciones

pragma | YouTube

Contextualización
Objetivo

Resumen del Reto
se requiere en proceso de expansión hacia el mercado estadounidense. Como parte de la estrategia de posicionamiento, se desea fortalecer su presencia en YouTube mediante la creación de un canal que genere tráfico hacia su sitio web y potencialmente atraiga nuevos negocios.

Para ello, requiere entender el comportamiento de esta plataforma: identificar los tipos de videos que logran mayor interacción, los factores que los vuelven tendencia, y si es posible predecir su éxito a partir de ciertas características.



Objetivo
Analizar los datos de los videos de la red social de YouTube en Estados Unidos para identificar patrones y características claves y posiblemente construir modelos que permitan tomar decisiones estratégicas.

Metodología CRISP-DM

(Cross-Industry Standard Process for Data Mining)



1 Obtención de los datos

Archivo CSV
Videos en tendencia (EE. UU.)

Archivo JSON
Información de categorías de videos

Datos originales
40.901 registros
6.351 videos únicos

2 Análisis exploratorio

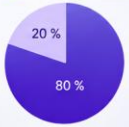
- Estadística descriptiva (univariado y bivariado)
- Distribución de vistas, likes y comentarios
- Categorías de videos
- Canales
- Temporalidad de publicación
- Análisis de texto (títulos, tags y descripciones)

3 Preparación de los datos

- Eliminación de registros inválidos
- Tratamiento de valores faltantes
- Transformación de variables
- Codificación de variables categóricas
- Creación de variables predictoras (5 variables clave)
- Construcción de la variable objetivo (alta interacción: tasa de likes > 4,08 %)
- Conjunto final de datos

Datos procesados
Variables numéricas, categóricas y de texto listas para modelar

4 División de los datos



- Partición estratificada
- 80 % datos de entrenamiento
- 20 % datos de prueba
- Misma proporción de clases en ambos conjuntos

5 Modelamiento

- Regresión Logística (class_weight = balanced)
- Random Forest

Estrategia
- Validación cruzada en el conjunto de entrenamiento
- Ajuste de hiperparámetros

6 Evaluación, interpretación y recomendaciones

Evaluación del desempeño
- Matriz de confusión
- Precisión, recall y F1-score (clase 1)
- Curvas de aprendizaje
- Comparación de modelos

Interpretación y uso de resultados
- Importancia de variables (SHAP)
- Factores asociados a mayor interacción
- Recomendaciones para la estrategia de contenido

Modelo orientado a priorizar contenidos con potencial de alta interacción, no a garantizar su éxito.

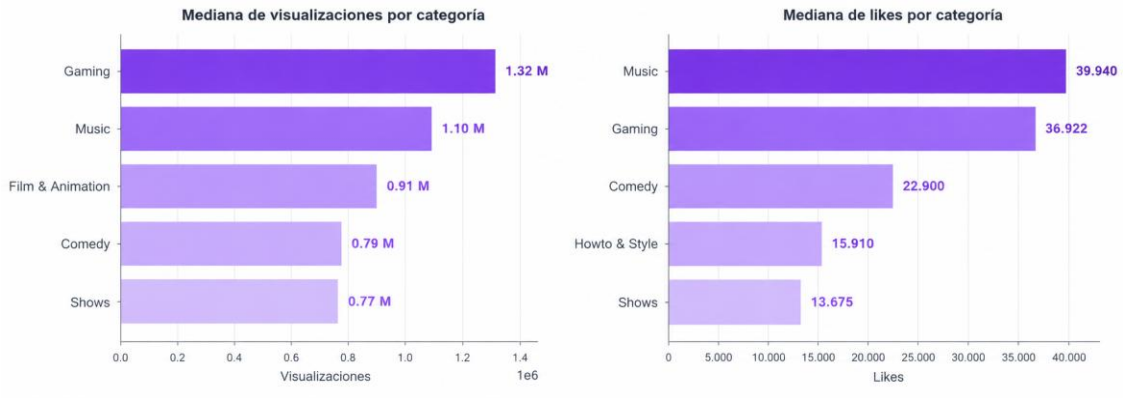
1. ¿Cómo se distribuye la popularidad de los videos en YouTube?

518 mil
Mediana de visualizaciones

1,96 M
Promedio de visualizaciones

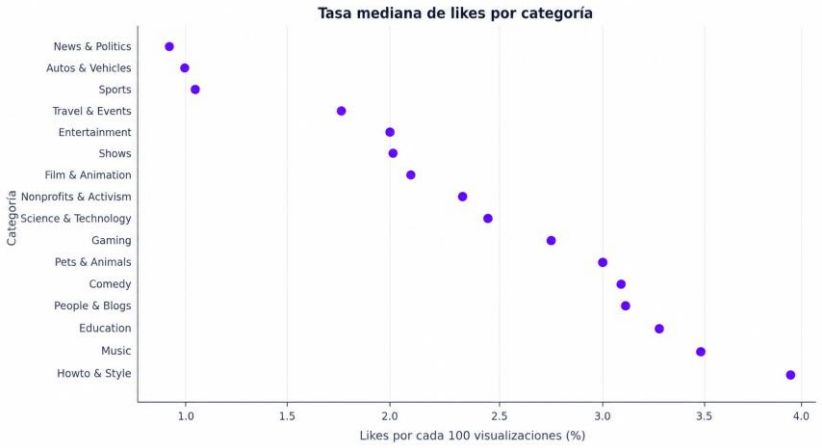
La mayoría de los videos concentra menos visualizaciones, mientras unos pocos alcanzan cifras extraordinarias y elevan el promedio.

2. ¿Qué categorías de videos reciben más visualizaciones y likes?



Gaming (videojuegos) lidera en visualizaciones y Music (música) en likes, destacándose como categorías de alto alcance.

3. ¿Qué proporción de las visualizaciones se traduce en likes?



Howto & Style registra la mayor tasa mediana de likes (3,98 %), superando a Music (3,51 %) y Gaming (2,79 %). Esto evidencia que mayor alcance no siempre implica mayor interacción proporcional.

4. ¿¿El día de publicación influye en el desempeño de los videos?

Día de publicación	Cantidad de videos	Mediana de visualizaciones
Saturday	547	**570.053**
Thursday	1.056	565.320
Friday	1.047	562.298
Sunday	559	537.443
Monday	985	502.040
Wednesday	1.097	462.063
Tuesday	1.060	**451.533**

Los videos publicados los sábados presentan la mayor mediana de visualizaciones (570 mil), lo que sugiere explorar este día como alternativa para mejorar el alcance

5. ¿Qué palabras clave son más comunes en los tags de videos con mayor número de vistas?

1 día

Mediana general de tiempo hasta tendencias

75%

Aparece en tendencias en aproximadamente 2 días o menos

Categoría	Cantidad de videos	Tiempo mediano (días)
Comedy	547	**1.0**
Gaming	103	**1.0**
Music	799	**1.0**
News & Politics	505	**1.0**
Sports	451	**1.0**
Education	250	2.0
Entertainment	1.619	2.0

6. ¿Cuáles son los canales con más videos en tendencia y qué nivel de interacción generan?

Canal	Cantidad de videos	Mediana de visualizaciones	Tasa mediana de likes
ESPN	**84**	506.191	0.85
TheEllenShow	74	**883.050**	1.85
The Tonight Show Starring Jimmy Fallon	72	590.906	1.81
Jimmy Kimmel Live	70	874.775	1.56
The Late Show with Stephen Colbert	58	577.808	1.24
Netflix	58	433.453	1.78
NBA	55	293.295	1.27
CNN	52	327.963	0.85
Vox	47	655.073	**2.68**
The Late Late Show with James Corden	46	814.663	2.23

ESPN lidera en cantidad de videos en tendencia, TheEllenShow destaca por su alcance y Vox por su mayor tasa de likes. Esto demuestra que mayor presencia no siempre implica mayor alcance o interacción

7. ¿Qué etiquetas son más frecuentes en los videos con mayor alcance?

202
Funny

181
Comedy

Se analizaron 1.588 videos del cuartil superior de visualizaciones. Las frecuencias corresponden a etiquetas presentes en los videos, no a efectos causales sobre su alcance.

#	Etiqueta (tag)	Cantidad de videos
1	funny	202
2	comedy	181
3	pop	91
4	trailer	79
5	music	73
6	late night	66
7	humor	66
8	comedian	64
9	live	56
10	review	52

MODELAMIENTO

Definición del problema

Construimos un modelo de clasificación binaria para identificar videos con alta interacción.

- Variable objetivo: alta interacción (alta interacción).
- Criterio: tasa de likes superior al percentil 75, aproximadamente 4,08 %.
- Datos: 6.351 videos únicos.
- Distribución: 25 % con alta interacción y 75 % sin alta interacción.

Variable	Tipo	Descripción	Valores o ejemplos
category_name	Categórica	Categoría a la que pertenece el video.	Ej.: Music, Comedy, Gaming, News, Sports, ...
dia_publicacion	Categórica	Día de la semana en que se publicó el video.	Lunes, Martes, Miércoles, Jueves, Viernes, Sábado, Domingo
hora_publicacion	Categórica	Hora de publicación del video, expresada en UTC.	0, 1, 2, ..., 23
longitud_titulo	Numérica	Número de caracteres que contiene el título del video.	Ej.: 25, 48, 76, ...
cantidad_tags	Numérica	Cantidad de etiquetas asociadas al video.	Ej.: 0, 3, 5, 10, ...
alta_interaccion	Binaria (objetivo)	Indica si el video supera el percentil 75 de la tasa de likes.	1 = alta interacción 0 = no alta interacción

Modelos utilizados

Regresión Logistica

Modelo lineal de clasificación binaria que estima la probabilidad de alta interacción.Se utilizó ponderación de clases (balanced) para atender el desbalance de los datos y facilitar la interpretación de las variables.

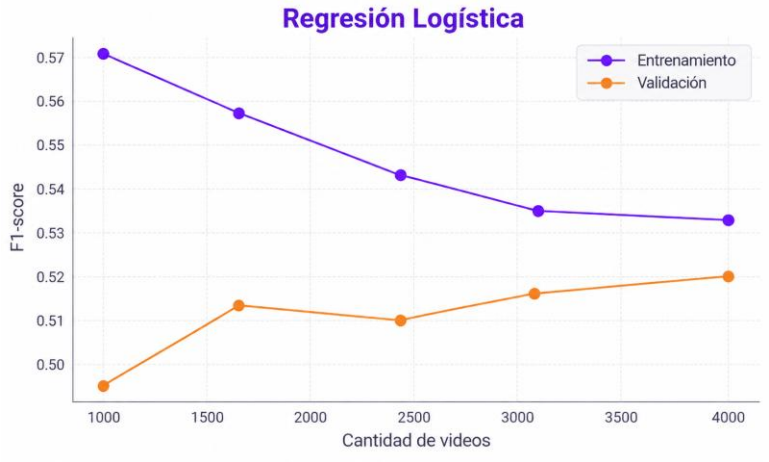
Bosque Aleatorio

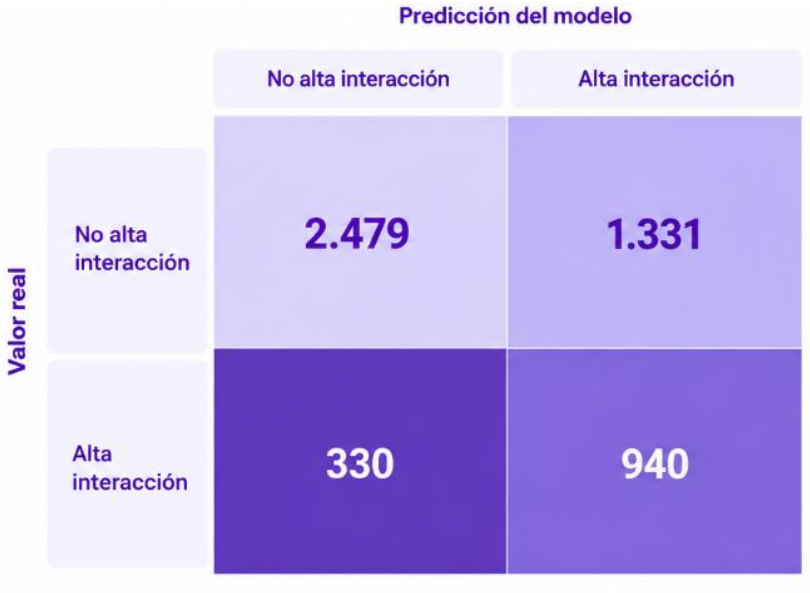
Modelo de clasificación que combina 200 árboles de decisión para capturar relaciones no lineales entre las variables.También se aplicó ponderación de clases (balanced) y procesamiento paralelo.

Resultados del modelo

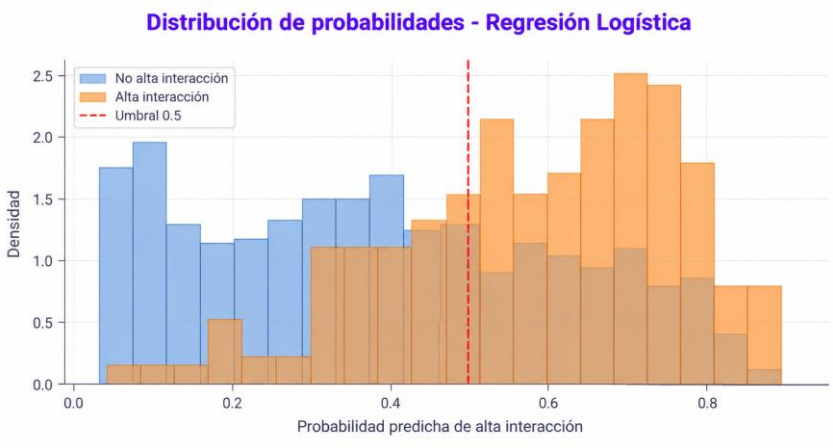
Regresión Logística

	precision	recall	f1-score	support
No alta interacción	0.883	0.651	0.749	3810
Alta interacción	0.414	0.740	0.531	1270
accuracy			0.673	5080
macro avg	0.648	0.695	0.640	5080
weighted avg	0.765	0.673	0.695	5080

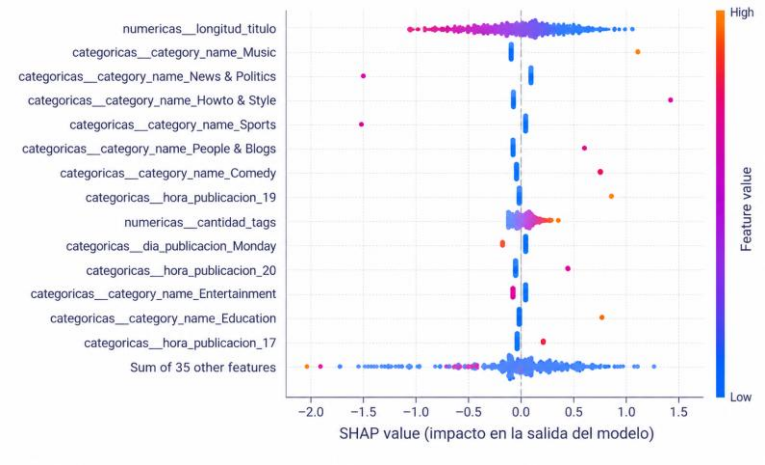




Interpretabilidad del modelo y potencial de interacción



El modelo tiende a asignar probabilidades más altas a los videos con alta interacción y más bajas a los demás. Sin embargo, existe un solapamiento entre ambos grupos, lo que evidencia que el modelo permite priorizar contenidos con mayor potencial, pero no garantiza su éxito.



La longitud del título y la categoría del video son los factores que más influyen en las predicciones. Los títulos cortos y categorías como música, comedia y estilo de vida se asocian con mayor potencial de interacción. Estos hallazgos permiten orientar estrategias de contenido

Conclusiones

1. El alcance no garantiza interacción. Gaming lidera en visualizaciones, mientras que Howto & Style presenta la mayor tasa mediana de likes (3,98 %). La estrategia debe diferenciar ambos objetivos.

2. El contenido importa más que el momento de publicación. La categoría y la longitud del título destacan en el modelo predictivo, mientras que el día y la hora tienen menor influencia.

3. El modelo aporta valor para priorizar, no para garantizar resultados. La regresión logística alcanza un F1 de 0,52 en validación cruzada y permite identificar contenidos con mayor potencial, aunque su capacidad predictiva es moderada.

Recomendaciones

1. Diseñar estrategias según el objetivo: priorizar Gaming y Music para explorar alcance, y Howto & Style para fomentar interacción.

2. Experimentar con títulos más cortos y contenidos orientados al humor y la comedia, tendencias destacadas en el análisis, mediante pruebas A/B que permitan evaluar su impacto real en el alcance y la interacción.

3. Utilizar el modelo como herramienta de apoyo editorial, priorizando contenidos según su puntuación y validando periódicamente su desempeño con nuevos datos.